

Rapport TAL

Maël Fauquette
Souleymane Barry

March 11, 2026

1 Exercice 1 : Classification de Clauses Juridiques

L’objectif de cet exercice est de prédire la catégorie juridique de clauses contractuelles issues du jeu de données LEDGAR. Cette tâche évalue la capacité des modèles à capturer des distinctions sémantiques fines dans un langage juridique formel.

1.1 Méthodologie et Choix des Modèles

Conformément aux instructions, nous avons constitué un benchmark comparatif de cinq modèles génériques, adaptés aux contraintes du serveur `vdigpu`:

- **Modèles Encoder-only** : DistilBERT (en *Linear Probing* et en *LoRA*) ainsi que DistilRoBERTa (en *LoRA*). Ces modèles sont choisis pour leur efficacité naturelle dans les tâches de compréhension de texte.
- **Modèle Decoder-only** : DistilGPT2 (*Linear Probing*), afin d’évaluer la capacité d’un modèle auto-régressif à effectuer de la classification.
- **Modèle Encoder-Decoder** : T5-small (*LoRA*), pour tester une architecture polyvalente sur une tâche de classification.

1.2 Préparation des données

Tous les modèles s’appuient sur le jeu de données **LEDGAR** issu de *LexGLUE*.

- **Définition de la tâche** : Le problème est une classification supervisée comportant 100 classes distinctes.
- **Tokenisation et formatage** : Une stratégie de troncature et de *padding* est fixée à une longueur maximale de 256 jetons (`MAX_LENGTH`) pour gérer la longueur des textes juridiques.
- **Chargement** : L’entraînement s’effectue par mini-lots (*batches*) de 16 exemples.

1.3 Mécanismes de Classification et Optimisation

1.3.1 Stratégies de classification (Justification)

Pour les architectures où la classification n'est pas native (Decoder-only et Encoder-Decoder), nous avons adopté les stratégies suivantes:

- **DistilBERT** : Utilisation du vecteur d'état caché du jeton spécial [CLS] passé à une tête de classification linéaire.
- **DistilGPT2** : La classification est effectuée via une couche de *score* appliquée au dernier jeton de la séquence, après avoir configuré le `pad_token_id` sur le `eos_token_id`.
- **T5-small** : Utilisation de la classe `AutoModelForSequenceClassification` qui adapte l'architecture encodeur-décodeur pour produire des logits de classification à partir des représentations internes.

1.3.2 Configuration de l'optimisation

- **Sondage Linéaire (Linear Probing)** : Le corps du modèle est gelé. Seule la tête de classification est entraînée avec un taux d'apprentissage de 1×10^{-3} .
- **Ajustement par LoRA (PEFT)** : Utilisation de la méthode *Low-Rank Adaptation* avec un rang $r = 8$ et $\alpha = 16$ sauf pour le T5 qui lui a un rang $r = 16$ et $\alpha = 32$. Le taux d'apprentissage est fixé à 2×10^{-4} pour optimiser les adaptateurs sans déstabiliser le modèle pré-entraîné.
- **Répétabilité** : Chaque expérience est répétée sur 3 *runs* avec des graines aléatoires différentes (42, 123, 999) pour rapporter la moyenne et l'écart-type des métriques.

1.4 Gestion des contraintes computationnelles

Pour garantir l'exécution sur l'environnement `vdigpu`, les techniques suivantes ont été implémentées:

- **Précision Numérique** : Utilisation de la **précision mixte** (*Mixed Precision*) via `torch.amp.autocast` pour accélérer les calculs et limiter l'usage de la VRAM.
- **Efficacité Paramétrique** : Le gel sélectif des couches (*Linear Probing*) et l'usage de *LoRA* (PEFT) réduisent drastiquement le nombre de paramètres à optimiser.
- **Gestion Mémoire** : Nettoyage systématique du cache GPU (`torch.cuda.empty_cache()`) et invocation du ramasse-miettes (`gc.collect()`) entre chaque exécution.

1.5 Résultats du Benchmark

Les performances sont évaluées selon trois métriques obligatoires : l’Accuracy, le Macro F1-score et l’AUROC.

Table 1: Benchmark results pour l’exercice 1 (3 runs par modèle)

Model	Architecture	Adaptation technique	Acc	F1	AUROC
DistilBERT	Encoder	Linear Probing	67.18 ± 0.52	0.53 ± 0.01	0.960 ± 0.010
DistilBERT	Encoder	PEFT (LoRA)	80.87 ± 0.25	0.71 ± 0.01	0.9814 ± 0.0001
RoBERTa	Encoder	PEFT (LoRA)	77.18 ± 0.13	0.64 ± 0.01	0.970 ± 0.011
T5-Small	Encoder-Decoder	PEFT (LoRA)	59.70 ± 1.16	0.31 ± 0.02	0.895 ± 0.004
DistilGPT-2	Decoder-only	Linear Probing	62.62 ± 0.64	0.48 ± 0.01	0.955 ± 0.001

1.6 Discussion

Les résultats obtenus mettent en évidence plusieurs tendances intéressantes. Les architectures **Encoder-only**, en particulier DistilBERT et RoBERTa, obtiennent les meilleures performances globales. Cela s’explique par leur capacité à encoder de manière bidirectionnelle le contexte complet de la clause juridique, ce qui est particulièrement adapté aux tâches de classification sémantique.

L’utilisation de **LoRA (PEFT)** améliore significativement les performances par rapport au *linear probing*. Par exemple, DistilBERT passe d’une accuracy de 67% à plus de 80%, ce qui montre que l’adaptation paramétrique permet au modèle d’ajuster ses représentations internes aux spécificités du domaine juridique.

Les modèles **Decoder-only**, comme DistilGPT2, obtiennent des performances correctes mais légèrement inférieures aux architectures encoder-only. Cela s’explique par le fait que ces modèles sont principalement conçus pour la génération auto-régressive et non pour l’analyse globale d’une séquence.

Enfin, les résultats du modèle **T5-small** montrent que les architectures Encoder-Decoder peuvent être utilisées pour la classification, mais qu’elles sont moins efficaces dans ce contexte précis que les modèles encoder-only spécialisés pour les tâches de compréhension de texte.

2 Exercice 2 : Résumé de documents juridiques (BillSum)

2.1 Description de la tâche et du corpus

Cette tâche consiste en la génération de résumés abstraits à partir de textes législatifs du Congrès des États-Unis (BillSum). Le défi majeur réside dans la longueur importante des documents sources et la technicité du langage juridique, nécessitant une sélection d’informations rigoureuse et une grande fidélité au texte original.

2.2 Modèles et stratégies d’adaptation

Nous avons évalué cinq configurations pour comparer différentes architectures et techniques d’adaptation :

- **DistilBERT-base (BertSum)** : Une approche extractive où le modèle sélectionne les phrases les plus pertinentes en utilisant une tête de classification sur les tokens [CLS] de chaque phrase.
- **T5-small (Full Fine-tuning)** : Une architecture Encoder-Decoder classique entraînée de manière exhaustive sur la tâche de résumé avec le préfixe "summarize: ".
- **T5-small (LoRA)** : Adaptation du même modèle T5 en utilisant la technique LoRA (Low-Rank Adaptation) pour réduire le nombre de paramètres entraînaables.
- **TinyLlama-1.1B (LoRA)** : Un modèle Decoder-only adapté via LoRA. La tâche est formulée par un prompt d’instruction : *"Summarize this legal text..."*.
- **DistilGPT2 (LoRA)** : Une version compressée de GPT-2, également adaptée via LoRA avec une formulation par prompt similaire.

2.3 Configuration expérimentale et contraintes

Pour garantir la reproductibilité et la stabilité des résultats, chaque modèle a été entraîné sur 3 runs avec les graines aléatoires {42, 123, 999}.

Afin de respecter les contraintes de mémoire du GPU (vdigpu), les techniques suivantes ont été appliquées :

- **Précision Mixte (AMP)** : Utilisation de `torch.amp` pour accélérer les calculs.
- **Troncation des séquences** : Limitation de la longueur d’entrée (ex: 512 tokens pour T5) pour éviter les erreurs de mémoire.
- **PEFT** : Utilisation de LoRA pour les modèles volumineux (TinyLlama) afin de ne mettre à jour qu’une fraction des poids.

2.4 Résultats du Benchmark

Le tableau suivant présente les moyennes et écart-types des métriques ROUGE-1, ROUGE-2 et BLEU obtenues sur le jeu de test.

Table 2: Benchmark results pour l'exercice 2 (3 runs par modèle)

Modèle	Architecture	Adaptation	ROUGE-1	ROUGE-2	BLEU
DistilBERT	Encoder (BertSum)	Extractive Head	0.3801 ± 0.0028	0.1731 ± 0.0008	0.1251 ± 0.0046
T5-small	Encoder-Decoder	Full Fine-tuning	0.3763 ± 0.0037	0.1536 ± 0.0019	0.1294 ± 0.0026
T5-small	Encoder-Decoder	LoRA (PEFT)	0.3803 ± 0.0022	0.1591 ± 0.0018	0.1417 ± 0.0020
TinyLlama-1.1B	Decoder-only	LoRA (PEFT)	0.3008 ± 0.0022	0.0952 ± 0.0032	0.0856 ± 0.0013
DistilGPT2	Decoder-only	LoRA (PEFT)	0.2954 ± 0.0026	0.1045 ± 0.0005	0.0921 ± 0.0001

2.5 Discussion

Les résultats montrent que les modèles de type **Encoder-Decoder** (T5) et **Encoder-only** (BertSum) surpassent les modèles **Decoder-only** sur ce dataset spécifique. Cela s'explique par la capacité des architectures bidirectionnelles à mieux encoder les longs documents juridiques avant la phase de génération. On note également que l'adaptation LoRA sur T5-small offre des performances compétitives, voire supérieures au fine-tuning complet, tout en étant plus stable. Les modèles Decoder-only (TinyLlama, DistilGPT2) montrent des scores plus faibles, probablement en raison de la contrainte sur la longueur de contexte et de la difficulté à générer un résumé structuré sans un pré-entraînement plus massif sur le domaine juridique.

3 Exercice 3 : Explication de clauses juridiques

3.1 Description de la tâche et objectifs

L'objectif de cet exercice est de transformer des clauses contractuelles complexes du corpus LEDGAR en explications accessibles pour un public non-expert. La tâche consiste à définir une fonction de génération h_θ visant à produire un texte en anglais simple, tout en garantissant la fidélité au contenu original sans introduire de nouvelles obligations juridiques ou interprétations abusives. Contrairement aux exercices précédents, cette phase privilégie l'évaluation de la génération contrôlée et du raisonnement qualitatif plutôt que la simple précision prédictive.

3.2 Stratégies de modélisation et benchmark

Conformément aux directives, nous avons sélectionné des modèles de type *decoder-only* pour évaluer différentes approches de génération contrôlée. Le benchmark se décline en trois méthodologies distinctes :

3.3 Analyse approfondie des implémentations techniques

3.3.1 Adaptation par bas rang (LoRA)

L'adaptation paramétrique efficace a été mise en œuvre pour spécialiser les modèles sans altérer leurs capacités généralistes.

Table 3: Benchmark experiments pour l’Exercice 3

Modèle	Technique d’adaptation	Stratégie de Prompting
GPT-2 (base)	Zero-shot (Prompt-based)	Instruction directe et définition de rôle
GPT-2 (base)	Few-shot ($k = 2$)	Démonstrations avec explications manuelles
DistilGPT2	PEFT (LoRA)	Fine-tuning sur cibles synthétiques
Qwen2.5	PEFT (LoRA)	Fine-tuning sur cibles synthétiques
TinyLlama-1.1B	Chat Instruction	Format de dialogue (Instruction-style)

- **Cibles de projection** : Pour DistilGPT2, les adaptateurs ciblent `c_attn` et `c_proj`. Pour Qwen2.5-0.5B, l’adaptation est étendue aux modules `q_proj`, `k_proj`, `v_proj` et `o_proj` pour une meilleure capture sémantique.
- **Hyperparamètres** : Un rang $r = 8$ et un facteur $\alpha = 16$ ont été utilisés pour équilibrer plasticité et stabilité.
- **Cibles synthétiques** : En l’absence de labels d’explication ”gold”, nous avons généré des cibles basées sur les noms de catégories LEDGAR pour orienter le modèle vers une description fonctionnelle de la clause.

3.3.2 Ingénierie de Prompt et Contrôle

Pour les modèles non-ajustés, la performance repose sur la précision de l’instruction (système de rôle) et la gestion du contexte.

- **Rôles et Contraintes** : Chaque prompt définit le modèle comme un ”careful educational legal assistant” avec interdiction explicite d’ajouter des obligations ou de donner des conseils juridiques.
- **Few-shot** ($k = 2$) : L’inclusion de démonstrations manuelles permet de stabiliser le format de sortie et le ton pédagogique sur des modèles de petite taille comme GPT-2.

3.4 Gestion des risques et arbitrage du décodage

L’utilisation de décodeurs comporte des risques d’hallucination juridique majeurs. Notre stratégie de mitigation repose sur deux leviers :

3.4.1 Détection heuristique des risques

Nous avons implémenté des ”flags” de risque basés sur des expressions régulières pour identifier les dérives en post-génération :

- **mentions_new_obligations** : Détecte l’usage de verbes modaux contraignants (*shall*, *must*) absents de la source.
- **gives_legal_advice** : Repère les structures de conseil (*you should*, *consult a lawyer*).
- **mentions_deadlines** : Identifie l’invention de délais temporels fictifs.

3.4.2 Comparaison des modes de décodage

Chaque expérience compare systématiquement deux configurations pour analyser le compromis entre créativité et fidélité :

Table 4: Dualité de décodage pour la sécurité juridique

Paramètre	Mode SAFE	Mode RISKY
Stratégie	Beam Search / Greedy	Sampling (Top-p)
Température	0.0 (Déterministe)	0.7 (Fluide)
Pénalité de répétition	1.10	1.05
Top-p	1.0	0.9

3.5 Exemples qualitatifs

Afin d’illustrer plus concrètement les comportements observés, nous présentons ci-dessous plusieurs exemples réels d’explications générées par les modèles sur des clauses issues du jeu de test LEDGAR. Ces exemples mettent en évidence différents types de comportements génératifs, notamment des explications trop génériques, des hallucinations juridiques, ainsi que des explications globalement fidèles mais simplifiées.

3.5.1 DistilGPT2 avec LoRA : sortie grammaticalement propre mais trop générique

Clause originale

The Company, and the Buyers shall have the right to review a reasonable period of time before issuance of any press releases, SEC, Principal Market or FINRA filings, or any other public statements with respect to the transactions contemplated hereby; provided, however, that the Company shall be entitled, without the prior approval of the Buyers, to make any press release or regulatory filing with respect to such transactions as is required by applicable law and regulations.

Explication générée

This clause is about contracts. It describes the general terms and conditions related to this topic in the agreement. It should be read together with the rest of the contract for full context.

Commentaire

La sortie est syntaxiquement correcte et adopte bien un ton prudent, mais elle reste beaucoup trop générale. Le modèle ne parvient pas à identifier le sujet réel de la clause, qui concerne ici la validation et la publication de communications publiques ou réglementaires. Cet exemple illustre une limite importante du fine-tuning sur cibles synthétiques : le modèle apprend une forme d’explication, sans toujours capturer précisément le contenu sémantique de la clause.

3.5.2 GPT-2 zero-shot : hallucination de contenu juridique

Clause originale

All disclosure provided to the Members regarding OHGI, its business and Transactions, including the OHGI Disclosure Schedules to this Agreement, are true and correct and do not contain any untrue statement of a material fact or omit to state any material fact necessary in order to make the statements made therein not misleading. If the disclosure schedules are not delivered at the same time as the agreement, they must be delivered as soon as practicable before the Closing Date.

Explication générée

The following is a summary of the terms and conditions of this agreement. This Agreement is governed by the laws of the State of California. This Agreement shall be governed by and construed in accordance with the laws and regulations of the United States of America.

Commentaire

Cette sortie constitue un exemple clair d'**hallucination juridique**. Le modèle introduit des éléments qui n'apparaissent pas dans la clause originale, notamment des références au droit applicable et à des dispositions de *governing law*. Il ne reformule donc pas la clause source, mais génère au contraire un fragment contractuel générique et erroné. Ce type de comportement est particulièrement problématique dans un cadre juridique, car il peut produire des interprétations inexactes tout en conservant une forme apparemment crédible.

3.5.3 TinyLlama : explications globalement fidèles mais simplifiées

Clause originale

Except as expressly set forth herein, the representations and warranties contained in this Agreement shall survive the Closing Date and remain in full force and effect for a period of two years following the Closing Date. However, certain specific sections shall survive until the expiration of the applicable statute of limitations.

Explication générée

This legal clause states that certain representations and guarantees contained in the agreement will continue to be valid for a specific period of time, which is two years from the date of the closing. The representations contained in certain sections will remain valid until the applicable statute of limitations expires.

Commentaire

Dans cet exemple, le modèle identifie correctement l'idée principale de la clause : certaines garanties et déclarations restent valides après la signature du contrat pendant une durée déterminée. L'explication simplifie le langage juridique tout en conservant l'information essentielle. Toutefois, la formulation reste approximative et la structure juridique exacte de la clause est légèrement simplifiée. Ce comportement est représentatif des résultats observés pour TinyLlama, qui produit généralement des explications plus proches du texte source que GPT-2, mais reste sensible à la complexité syntaxique des clauses juridiques.

3.6 Discussion et analyse des comportements

- **Instabilité et hallucinations** : Les modèles de base en mode *Risky* tendent à inventer des entités nommées, des obligations supplémentaires ou des dispositions contractuelles absentes du texte original. Ce phénomène est particulièrement visible avec GPT-2 en configuration zero-shot.
- **Influence du prompting** : Les stratégies de prompting (zero-shot, few-shot et instruction-style) influencent fortement la qualité des explications produites. Les prompts structurés définissant un rôle clair pour le modèle et des contraintes explicites permettent généralement d'améliorer la lisibilité et la sécurité des sorties générées.
- **Efficacité du LoRA** : L'ajustement LoRA, même sur un volume de données relativement limité (1000–8000 exemples), permet de stabiliser le style des explications produites et de réduire certaines dérives génératives, notamment les répétitions ou les fragments contractuels génériques.
- **Arbitrage entre contrôle et flexibilité** : Le mode *Safe* (déterministe) permet de limiter les hallucinations et favorise la fidélité au texte source, mais réduit la variété lexicale des explications. À l'inverse, les modes de génération basés sur l'échantillonnage produisent des sorties plus naturelles mais plus instables.

Enfin, il est important de souligner certaines limites des modèles **decoder-only** pour cette tâche. Ces architectures sont optimisées pour la génération auto-régressive et peuvent parfois simplifier excessivement le contenu juridique ou omettre certaines nuances présentes dans la clause originale. Les formulations conditionnelles complexes ou les références implicites entre différentes parties du contrat peuvent être difficiles à interpréter correctement pour des modèles génératifs de petite taille.

Ces observations suggèrent que l'explication automatique de clauses juridiques reste une tâche délicate, nécessitant un équilibre entre lisibilité pour un public non-expert et fidélité au texte juridique initial. Elles mettent également en évidence les limites des petits modèles génératifs dans des domaines spécialisés comme le droit, où la précision terminologique et la structure logique des clauses jouent un rôle essentiel.